

Синтетические респонденты в анкетном опросе: эмпирическая проверка на данных опроса студентов

Инна Александровна Газиева

Российская академия народного хозяйства и государственной службы при Президенте РФ (РАНХиГС), Москва, Россия

ORCID: [0000-0002-0778-7171](https://orcid.org/0000-0002-0778-7171) · gazieva-ia@ranepa.ru

Препринт. Не проходил рецензирование. DOI: [10.5281/zenodo.22939959](https://doi.org/10.5281/zenodo.22939959)

Аннотация. Целью статьи является эмпирическая проверка пределов применимости синтетических респондентов, то есть больших языковых моделей, отвечающих на вопросы анкеты от лица «цифровых двойников», сконструированных на основе социально-демографических характеристик реальных людей. В отличие от большинства опубликованных проверок, выполненных на зарубежных общенациональных опросах, в работе использованы данные собственного исследования автора, в котором ответ каждого живого участника заранее известен. Эмпирической базой послужили данные опроса студентов РАНХиГС в рамках программы «Научный код» (2024 г., N = 1795, анкета из 39 вопросов). Для каждого респондента построен двойник на основе пяти признаков, взятых целиком из его строки массива (пол, уровень и курс обучения, филиал, укрупнённое направление подготовки, национальность); языковая модель DeepSeek в 64 620 независимых обращениях заново прошла 36 кодируемых вопросов анкеты. Результаты показали, что двойник воспроизводит центральную тенденцию и направление демографических различий (направление гендерных различий совпало на 85% пунктов), однако систематически сужает разброс ответов (среднее стандартное отклонение 0,52 против 1,04 у людей), избегает крайних позиций шкалы (36% против 50%) и варианта «затрудняюсь ответить», вдвое ослабляет связи между ответами на вопросы разных тематических блоков (средний модуль коэффициента корреляции 0,10 против 0,27) и практически не передаёт индивидуальность респондента (совпадение «своего» двойника с человеком 37,9% против 36,5% у случайного). Научная новизна работы состоит в разграничении трёх уровней, на которых синтетический респондент ведёт себя принципиально по-разному: уровня распределений, уровня разброса и уровня связей и индивидуальных ответов. Делается вывод о том, что синтетический респондент является не измерительным инструментом, а средством подготовки измерения (апробации анкеты), и формулируется гипотеза об использовании расхождений между ответами людей и двойников для выявления социально желательных ответов.

Ключевые слова: синтетические респонденты, силиконовая выборка, большие языковые модели, анкетный опрос, методология социологических исследований, социальная желательность, студенческая молодёжь

Введение

Эмпирическая социология и смежные с ней отрасли прикладных исследований сегодня столкнулись с системным кризисом классических методов сбора данных. Традиционный анкетный опрос, долгое время служивший «золотым стандартом», становится всё более уязвимым: полевые работы дорожают, сроки их проведения растягиваются, показатели

отклика снижаются, а «усталость» респондентов и эффект социальной желательности всё чаще искажают получаемое социальное знание. Закономерно возникает потребность в цифровых альтернативах, которые позволили бы измерять характеристики социальных явлений быстрее, масштабнее и дешевле.

Одной из таких альтернатив стали так называемые синтетические респонденты (в литературе также «силиконовая выборка», ИИ-респонденты, виртуальные респонденты), то есть большие языковые модели, которые отвечают на вопросы анкеты от лица «цифрового двойника», сконструированного на основе демографического описания реального человека. Сервисы, предлагающие готовые «алгоритмические панели», уже вышли на открытый рынок, и для молодого исследователя, не располагающего значительным бюджетом, соблазн делегировать сбор мнений нейросети становится практически непреодолимым.

Вместе с тем границы применимости подобных симуляций остаются, на наш взгляд, «серой зоной». Их валидность чаще всего обсуждается на чужих данных и абстрактных кейсах, из-за чего практикующему исследователю трудно понять, где заканчивается социальная реальность и начинается алгоритмическая иллюзия, каким метрикам синтетических данных можно доверять и какие скрытые искажения делают их использование научно несостоятельным.

Целью настоящей статьи является эмпирическая проверка пределов применимости синтетических респондентов на материале собственного исследования, в котором ответ каждого живого участника заранее известен. Для этого синтетический двойник строится для каждого из 1795 участников опроса, после чего два массива, человеческий и синтетический, закодированные по одним правилам, сравниваются на уровне распределений, разброса ответов, связей между ними и отдельных респондентов.

Обзор литературы

Идея синтетических респондентов восходит к работе Л. Аргайла с коллегами (Argyle et al., 2023), в которой введены понятия «силиконовой выборки» и «алгоритмической точности»: языковая модель, обусловленная демографическими характеристиками, воспроизводит часть агрегированных распределений реальных опросов. К оптимистичной линии примыкает обзор М. Зарштедта с коллегами (Sarstedt et al., 2024), рассматривающий возможности и риски силиконовых выборок в маркетинговых исследованиях, а также работа С. Сана с коллегами (Sun et al., 2024), в которой мнения подгрупп порождаются на основе групповых демографических данных, хотя и с оговоркой, что воспроизводимость зависит от группы и темы вопроса.

Скептическая линия документирует три повторяющихся сюжета. Первый — схлопывание разброса: ответы моделей гомогенизируются и стягиваются к модальному варианту (Li, Li, Qiu, 2025; Dominguez-Olmedo, Hardt, Mendler-Dünnér, 2024). Второй — потеря структуры связей между переменными: по данным Дж. Бисби с коллегами, синтетические ответы обладают меньшей вариацией, чем реальные, а регрессионные коэффициенты, рассчитанные на синтетических данных, часто значимо расходятся с полученными на данных опроса (Bisbee et al., 2024); по подсчёту К. О. Жуликова, расходились 48% коэффициентов, причём у 32% расхождений менялся знак эффекта (Жуликов, 2026, с. 152). Третий — недопредставленность меньшинств, растворяемых в «типичном» ответе. Существенно, что гомогенизация фиксируется и на крупнейших моделях своего времени: у Д. Ли с коллегами это GPT-4 и Llama 3.1 с 405 млрд параметров (Li, Li, Qiu, 2025), что позволяет полагать, что речь идёт о

структурном свойстве метода, а не о болезни роста, которую устранит следующая версия модели. Отдельная кросс-культурная линия показывает систематическое смещение моделей в сторону западных респондентов, в том числе на данных World Values Survey (Qu, Wang, 2024; AlKhamissi et al., 2024).

Русскоязычная литература по проблеме только складывается. Ж. В. Пузанова с коллегами (Пузанова, Кожоридзе, Кожоридзе, 2025), отмечая, что отечественных эмпирических проверок пока немного, испытали «виртуального респондента» в качественном жанре, на фокус-группах молодёжи: ответы модели оказались обобщёнными, без конкретных примеров и с пропущенными позициями, а высокое совпадение во втором эксперименте авторы сами объясняют тем, что модель обобщала уже полученные от людей данные. К. О. Жуликов, разобрав публикации 2022–2026 годов, отмечает, что ответы моделей «в повторных тестах напоминали ответы одного и того же человека, а не разных респондентов», и считает применение синтетических респондентов обоснованным «на подготовительных этапах работы» (Жуликов, 2026, с. 155–156). Е. Е. Кучко с коллегами предлагают ограничивать их разведывательными исследованиями и предварительным тестированием гипотез, результаты которых «подлежат обязательной последующей валидации посредством опроса реальных респондентов» (Кучко, Вишнякова, Марчук, 2025, с. 33).

Таким образом, большинство проверок выполнено на зарубежных общенациональных опросах, а отечественные работы носят либо обзорный, либо пилотный качественный характер. Количественных проверок на российских данных, в которых двойник сопоставляется с конкретным живым респондентом, в доступной автору литературе обнаружить не удалось; настоящая работа призвана частично восполнить этот пробел.

Данные и метод

Эмпирическая база. В качестве эталона использованы данные опроса студентов РАНХиГС, проведённого в 2024 году в рамках программы «Научный код» (N = 1795; анкета из 39 вопросов). Массив содержит ответ каждого участника на каждый вопрос, что позволяет сопоставлять синтетические ответы не только с агрегированными распределениями, но и с конкретными людьми. Первичные данные опроса не публикуются.

Построение двойника. Для каждого из 1795 респондентов построен синтетический двойник на основе пяти признаков: пол, уровень и курс обучения, филиал Академии, укрупнённое направление подготовки, национальность. Принципиально, что описание каждого двойника бралось целиком из строки одного живого респондента, а не собиралось из отдельных долей выборки. При формировании портретов путём перемножения маргинальных распределений (столько-то процентов девушек, столько-то первокурсников, столько-то будущих юристов) в выборке неизбежно возникли бы «невозможные» респонденты, например обучающиеся по направлению, которое в их филиале не реализуется. Заимствование строки целиком сохраняет совместное распределение признаков таким, каким оно существует в действительности.

Промпт персоны. Системная часть обращения к модели имела вид: «Ты — студент РАНХиГС. О тебе известно: {пол}, {курс}, {филиал}, направление подготовки — {направление}, национальность — {национальность}. Ответь на вопросы анкеты так, как ответил бы такой студент. Возвращай ТОЛЬКО код варианта ответа, без пояснений». Вопрос

подавался отдельно, с полным списком вариантов в виде «код — подпись» и требованием к формату ответа (одиночный выбор, шкальная матрица или множественный выбор).

Модель и процедура. Использовалась языковая модель DeepSeek (версия v4-flash, без режима рассуждения) с температурой 0,8, которая задаёт степень разнообразия ответов и оставляет модели свободу, не превращая её ответы в случайные. Анкета подавалась двойнику не целиком, а по одному блоку вопросов за обращение, и каждое обращение начиналось «с чистого листа»: модель не располагала сведениями о своих предыдущих ответах. Всего выполнено $1795 \times 36 = 64\,620$ независимых обращений (в сравнение вошли 36 вопросов из 39, поскольку три вопроса со свободным ответом не кодировались). Это принципиальное условие: получив анкету целиком, модель стала бы согласовывать ответы между собой, и измерялась бы её собственная внутренняя последовательность, а не способность воспроизводить людей.

Кодирование. Ответы принимались по строгому правилу: засчитывался только код существующего варианта ответа; из 64 620 ответов заданному формату не соответствовал один. Уклончивые варианты («затрудняюсь ответить», «не имею опыта») сохранялись отдельной категорией. Кодировка синтетического массива полностью повторяет кодировку человеческого, что и позволяет сравнивать их непосредственно.

Показатели сравнения. Сопоставление проводилось на четырёх уровнях: (1) совпадение ответов двойника и соответствующего человека (точное и в пределах одного балла шкалы); (2) разброс ответов (среднее по пунктам стандартное отклонение, доля крайних значений шкалы, доля варианта «затрудняюсь ответить»); (3) демографическая чувствительность (совпадение направления различий между подгруппами) и связи между ответами (средний модуль коэффициента корреляции между пунктами, относящимися к разным тематическим блокам анкеты); (4) индивидуальный уровень (согласие двойника со «своим» респондентом в сравнении со случайным).

Результаты

Совпадение ответов. Двойник отвечает «рядом» с человеком, но редко точно так же: точно совпало 37,8% ответов, в пределах одного балла шкалы — 79,1%.

Стягивание ответов к центру. Главным дефектом синтетических ответов является сужение разброса. Среднее стандартное отклонение ответов у двойников вдвое меньше человеческого (0,52 против 1,04), а крайние позиции шкалы они выбирают заметно реже (36% против 50%). Реальные мнения распределены широко, синтетические же собираются в узкую полосу вокруг среднего значения.

Неуверенность. Двойник почти не выражает неуверенности. Там, где живые студенты выбирают вариант «затрудняюсь ответить» в 13–19% случаев, у модели этот вариант не встречается практически никогда. Показательным является исключение: в вопросах, где нулевой код означает фактическое отсутствие опыта («не имею опыта»), а не затруднение с ответом, модель выбирает его наравне с людьми. Иными словами, модель избегает именно «не знаю», но не «не делал».

Демографическая чувствительность. Демографический портрет при этом работает: направление гендерных различий воспроизводится у двойников на 85% пунктов, то есть модель отвечает за разных респондентов по-разному, в целом отражая заданные социально-демографические характеристики. Вместе с тем нетипичные и малочисленные группы

воспроизводятся хуже: студенты ИТ-направлений совпадали со своими двойниками заметно реже, чем студенты «типичных» юридических и управленческих направлений (31,5% против 40,1%).

Индивидуальный уровень. Индивидуальность респондента двойником не передаётся: «свой» двойник похож на конкретного человека лишь немногим больше, чем случайный (37,9% против 36,5%).

Связи между ответами. У живых респондентов связи между ответами на вопросы разных тематических блоков втрое сильнее, чем у двойников (средний модуль коэффициента корреляции 0,27 против 0,10). Это означает, что двойник теряет характерную для людей взаимосвязь установок и практик, на которой строится анализ их структуры.

Случай социальной желательности. Наиболее показательным оказался вопрос об использовании ChatGPT: вариант «использую для генерации текста» выбрали 27,5% реальных студентов и 96,8% их двойников. На наш взгляд, модель, не склонная к самоцензуре, называет очевидное применение, тогда как живые респонденты его умалчивают, и в данном случае расхождение вскрывает занижение доли утвердительных ответов у людей, а не ошибку модели.

Обсуждение

Полученные результаты позволяют разграничить три уровня, на которых синтетический респондент ведёт себя принципиально по-разному.

На уровне распределений и направлений двойник работает. Распределения синтетических ответов по большинству пунктов лежат рядом с человеческими, а направление гендерных различий совпадает на 85% пунктов, поэтому на вопрос «в какую сторону смотрит группа» синтетика даёт разумное первое приближение.

На уровне разброса двойник ошибается систематически, в сторону сужения. Именно из разброса вычисляются величины, на которые опирается исследователь: сила различий между группами (размер эффекта), доверительные интервалы и объём выборки, необходимый для достоверного результата. Поскольку ответы двойников прижаты друг к другу теснее, чем ответы людей, все эти величины по синтетическим данным окажутся смещёнными. Существенно, что смещение носит не случайный, а закономерный характер и потому не устраняется увеличением числа двойников: сколько бы их ни было, отвечать они будут согласованнее, чем люди.

На уровне связей и отдельного человека двойник не работает. Связи между ответами на разные вопросы у него втрое слабее, а в литературе описаны случаи, когда связь на синтетических данных меняет знак (Bisbee et al., 2024; Жуликов, 2026, с. 152). Выстраивать на таком материале структуру ценностных установок (о методологии её измерения см.: Газиева, 2024) или предсказывать ответ конкретного человека, по мнению автора, невозможно.

Наши данные согласуются со скептической линией литературы и уточняют её на российском студенческом материале. Они также позволяют уточнить рекомендацию Ж. В. Пузановой с коллегами начинать с пилотного опроса на живых людях и лишь затем строить обобщённого виртуального респондента (Пузанова, Кожоридзе, Кожоридзе, 2025, с. 233): с первой частью этой рекомендации мы полностью согласны, однако обобщённый респондент, по словам

самих авторов, служит «репрезентации типичной позиции участников», а типичная позиция и есть то, к чему синтетика стягивает разброс.

Практическое применение. Из сказанного следует, что синтетический двойник является не измерительным инструментом, а средством подготовки измерения. Он полезен ровно до того момента, пока исследователь не начинает получать по нему цифры, которые намеревается вынести в текст своей работы: с этого момента он измеряет уже не мнения людей, а поведение языковой модели. К обоснованным применениям относятся: прогон черновика анкеты для выявления неудачных формулировок (если модель на каком-либо пункте систематически сбивается с формата ответа или все двойники выбирают один вариант, с большой вероятностью речь идёт о дефекте формулировки, а не о единодушии); сравнение двух редакций вопроса на одной и той же сетке персон; черновое представление о наборе вариантов ответа, которые в принципе могут выбираться, но не об их распределении.

Требования к описаниям персон зависят от притязаний исследователя. Для поиска неудачных формулировок репрезентативность непринципиальна: достаточно нескольких десятков персон, покрывающих «края популяции». Для утверждений о распределениях необходима совместная социально-демографическая структура, то есть построчные сведения об отдельных людях, а не сводные проценты. Их источниками могут служить административные данные собственной организации, данные ранее проведённых исследований той же группы (со всеми свойственными им смещениями), открытые массивы обследований и социально-демографический блок собственного пилотного опроса.

Гипотеза: языковая модель как зеркало самооценки. Расхождение в вопросе о ChatGPT подсказывает возможный методический приём. Если провести небольшой опрос на живых людях и сопоставить его результаты с ответами двойников, то вопросы с особенно большим расхождением могут указывать на пункты, в которых люди занижают или приукрашивают свои ответы. Такие пункты имеет смысл переводить в косвенные техники, например в списочный эксперимент. Подчеркнём, что как метод это не проверялось: в нашем распоряжении одно наблюдение по одному вопросу. Процедура не прогонялась на анкете с заранее известными чувствительными пунктами, не оценивалась частота ложных срабатываний, и отличить самооценку респондента от незнания моделью российских реалий ещё предстоит. До такой проверки сказанное является гипотезой для самостоятельного исследования, а не рекомендацией.

Ограничения исследования

Проверялась одна языковая модель на одной анкете и одной генеральной совокупности (студенты одного вуза), поэтому полученные выводы относятся к данной модели и данному инструменту; сравнение с другими моделями остаётся естественным продолжением работы. Температура генерации 0,8 является проектным решением, и агрегированные распределения зависят от этого выбора. Каждый двойник опрашивался однократно, что позволяет оценивать репрезентативность агрегата, но не устойчивость ответов отдельного двойника. Укрупнение направлений подготовки огрубляет соответствующий признак. Наконец, двойник знал о человеке только пять социально-демографических признаков; более богатые описания персон могут дать иные результаты на индивидуальном уровне, хотя, по данным литературы, не устраняют сужения разброса.

Заключение

Проведённая проверка показала, что синтетический респондент на основе большой языковой модели является «сглаженной тенью» реальной выборки: он угадывает направление, в котором делается вывод, но систематически теряет разброс, неуверенность, связи между ответами и индивидуальность респондента. Сказанное позволяет сформулировать принцип, который, на наш взгляд, распространяется на использование инструментов искусственного интеллекта в научной работе в целом: нейросеть ускоряет подготовительную работу, но не подменяет собой ни само измерение, ни проверку его результатов. Разумной является не замена людей моделью, а гибридная схема, в которой двойник ускоряет подготовку инструмента, а обязательный человеческий минимум остаётся условием измерения.

Список литературы

1. Газиева И. А. Социология ценностей: методология исследования : монография. — М. : ИНФРА-М, 2024. — 253 с. — DOI: [10.12737/2133680](https://doi.org/10.12737/2133680).
2. Жуликов К. О. Критерии оценки синтетических респондентов в качественных исследованиях: границы применимости // Интеракция. Интервью. Интерпретация. — 2026. — Т. 18, № 2. — С. 147–160. — DOI: [10.19181/inter.2026.18.2.5](https://doi.org/10.19181/inter.2026.18.2.5).
3. Кучко Е. Е., Вишнякова М. В., Марчук Я. И. Опрос синтетических респондентов: новые возможности или угроза достоверности данных? // Журнал Белорусского государственного университета. Социология. — 2025. — № 3. — С. 31–35. — URL: <https://elib.bsu.by/bitstream/123456789/350054/1/31-35.pdf>.
4. Пузанова Ж. В., Кожоридзе Г. Г., Кожоридзе Д. Г. ИИ и социология: анализ технологических возможностей виртуальных респондентов // Социология: методология, методы, математическое моделирование (Социология: 4М). — 2025. — № 60. — С. 216–246. — DOI: [10.19181/4m.2025.34.1.6](https://doi.org/10.19181/4m.2025.34.1.6).
5. AlKhamissi B., ElNokrashy M., AlKhamissi M., Diab M. Investigating Cultural Alignment of Large Language Models // Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL 2024). — 2024. — arXiv: [2402.13231](https://arxiv.org/abs/2402.13231).
6. Argyle L. P., Busby E. C., Fulda N., Gubler J. R., Rytting C., Wingate D. Out of One, Many: Using Language Models to Simulate Human Samples // Political Analysis. — 2023. — Vol. 31, No. 3. — P. 337–351. — DOI: [10.1017/pan.2023.2](https://doi.org/10.1017/pan.2023.2).
7. Bisbee J., Clinton J. D., Dorff C., Kenkel B., Larson J. M. Synthetic Replacements for Human Survey Data? The Perils of Large Language Models // Political Analysis. — 2024. — Vol. 32, No. 4. — P. 401–416. — DOI: [10.1017/pan.2024.5](https://doi.org/10.1017/pan.2024.5).
8. Dominguez-Olmedo R., Hardt M., Mendler-Dünner C. Questioning the Survey Responses of Large Language Models // Advances in Neural Information Processing Systems (NeurIPS 2024). — 2024. — arXiv: [2306.07951](https://arxiv.org/abs/2306.07951).
9. Li D., Li L., Qiu H. S. ChatGPT is not A Man but Das Man: Representativeness and Structural Consistency of Silicon Samples Generated by Large Language Models. — 2025. — arXiv: [2507.02919](https://arxiv.org/abs/2507.02919).
10. Qu Y., Wang J. Performance and biases of Large Language Models in public opinion simulation // Humanities and Social Sciences Communications. — 2024. — Vol. 11. — Art. 1095. — DOI: [10.1057/s41599-024-03609-x](https://doi.org/10.1057/s41599-024-03609-x).

11. Sarstedt M., Adler S. J., Rau L., Schmitt B. Using large language models to generate silicon samples in consumer and marketing research: Challenges, opportunities, and guidelines // *Psychology & Marketing*. — 2024. — Vol. 41, No. 6. — P. 1254–1270. — DOI: [10.1002/mar.21982](https://doi.org/10.1002/mar.21982).
12. Sun S., Lee E., Nan D., Zhao X., Lee W., Jansen B. J., Kim J. H. Random Silicon Sampling: Simulating Human Sub-Population Opinion Using a Large Language Model Based on Group-Level Demographic Information. — 2024. — arXiv: [2402.18144](https://arxiv.org/abs/2402.18144).